


측정에서 Strict Coefficient 까지

GPU/device-level energy · Treatment-Control · NCU path validation

핵심 해석


**workload-dependent effective
microbenchmark coefficient**

github.com/bang001/gpupower0701
branch main · HEAD 14fb27f · dirty worktree · 2026-07-12



무엇을 해결하려는 실험인가

GPU 전체에서 관측한 에너지를 , 경로가 검증된 미세벤치마크의 단위 작업당 증분으로 바꾼다 .



어떤 kernel 과 control 을 비교했는가 ?

NCU 는 무엇을 검증했는가 ?

어떤 gate 가 final 채택을 막는가 ?

NVML 은 어떤 scope 를 측정했는가 ?

분모는 expected 인가 actual traffic 인가 ?

플랫폼별 완료 상태는 어디까지인가 ?

측정하는 것과 측정하지 않는 것

말할 수 있는 것

NVML GPU/device-level energy 를
Treatment-Control 방식으로 차분하고,
NCU counter 로 경로 · traffic denominator 를 검증한
**workload-dependent effective
microbenchmark coefficient**


- 특정 kernel · working set · occupancy · clock 상태에 의존
- pJ/FLOP 또는 pJ/bit 는 정규화 단위
- GPU/device scope 이며 외부 board meter 측정과 동일하지 않음

말하면 안 되는 것


- × 순수 Tensor Core 회로 에너지
- × 순수 register-file access energy
- × 순수 SRAM/HBM/GDDR bitcell energy
- × 모든 application 의 GPU 고정 상수
- × **NCU 가 직접 측정한 component energy**

board-level 은 더 넓은 전원 경계를 암시한다 . 본 코드가 명시적으로 기록하는 scope 는 `gpu_device_total_energy_counter` 다 .


시스템 구성 : 한 workload, 두 관측 채널



GPU 계층과 실험이 거냥하는 경로




저장소 architecture map



우선순위 : 코드 ·CSV column → raw/NCU artifact → audit 결과 → 설명 문서

Current active treatment-control pair

Component/path	Treatment	Control	Final unit
Tensor MMA increment	reg_mma	reg_operand_only	pJ/FLOP
Shared scalar path	shared_scalar_load_only	clocked_empty	pJ/bit
Global L1 hit path	global_l1_load_only	global_addr_only	pJ/bit
L2 CG hit path	l2_cg_load_only	global_addr_only	pJ/bit
DRAM streaming sanity	dram_cg_load_only	global_addr_only	pJ/bit · sanity




Control의 역할

비용을 최대한 보존하고 target operation


주의 : l2_load_only 는 normal global load 이므로 strict L2-only 증거로 자동 채택하지 않는다 .

설명용 핵심 파이프라인



NCU 는 Energy Run 과 분리된 sidecar 다 . 같은 좌표의 실행 경로와 traffic 을 검증하지만 energy 를 측정하지 않는다 .

실제 command-package 파이프라인




어느 중간 단계가 실패해도 **triage artifact** 는 남기고 , **strict evidence package** 가 불완전하면 **shell** 은 **non-zero** 로 종료한다 .

Platform profile 과 blocks/SM sweep

Profile	SM	Shared/SM	L1+Shared/SM	L2	max blocks/SM	strict B/SM
RTX 3090	82	100 KiB	128 KiB	6 MiB	16	8
V100 32GB	80	96 KiB	128 KiB	6 MiB	32	32
A100	108	164 KiB	192 KiB	40 MiB	32	16
H100	132	228 KiB	256 KiB	50 MiB	32	16

플랫폼별 blocks/SM sweep와 strict NCU anchor


V100 B4/B16은 utilization 민감도 진단이며 strict anchor는 B32다. 요청 B는 실제 residency를 보장하지 않으므로 NCU occupancy/resource로 검증한다.



V100 은 B4/B16 민감도와 strict B32 를 측정한다 . 요청 B/SM 은 실제 동시 residency 가 아니므로 NCU occupancy/resource 로 확인한다 .


Platform 별 W_SM path sweep

플랫폼별 W_SM sweep: 의도한 경로 후보이며 자동 cache 이동이 아님



Shared는 별도 주소 공간이므로 W_SM 변화로 Global L1이 되지 않는다. Global load는 W_SM과 cache policy(.cg)로 후보를 만들고, NCU hit/access/bytes가 L1-L2-DRAM 채택을 결정한다.

CUDA host 실행 sequence



SMID gate: $\text{unique_SM} = \text{active_SM}$, $\text{total_blocks} = \text{active_SM} \times \text{blocks/SM}$, 각 사용 SM 에 동일한 resident block 수가 배치되어야 한다 .

NVML energy 와 idle-baseline 계산



$$\Delta E_{\text{raw}} = (E_{\text{after_mJ}} - E_{\text{before_mJ}}) / 1000$$

$$E_{\text{idle,scaled}} = E_{\text{idle}} \times t_{\text{kernel}} / t_{\text{idle}}$$

$$E_{\text{net}} = \Delta E_{\text{raw}} - E_{\text{idle,scaled}}$$

Final numerator gate

- ✓ `nvml_total_energy_supported = true`
- ✓ `energy_source = nvml_total_energy`
- ✓ `integration = total_energy_mj_delta`
- ✓ `scope = gpu_device_total_energy_counter`

GetPowerUsage = fallback/provisional
power.draw.* = metadata/diagnostic
Hopper module power · GPU memory power = component
numerator 사용 금지

Memory 차분 : duration scaling 과 DRAM 예외

Shared · Global L1 · L2

Treatment 와 control 의
ITER·elapsed 가 다를 수 있다 .

$$P_{\text{control}} = E_{\text{control},\text{net}} / t_{\text{control}}$$

$$E_{\text{control},\text{scaled}} = P_{\text{control}} \times t_{\text{treatment}}$$

$$\Delta E = E_{\text{treatment},\text{net}} - E_{\text{control},\text{scaled}}$$

elapsed ratio > 1.35 또는 신호가 너무 작으면 reject

DRAM final pair

현행 DRAM sanity 는
treatment/control work 를 동일하게 잠근다 .

$$\text{ITER}_{\text{dram}} = \text{ITER}_{\text{addr}}$$


$$\Delta E_{\text{DRAM}} = E_{\text{dram},\text{net}} - E_{\text{addr},\text{net}}$$

$$\text{pair_energy_basis} = \text{matched_iters_net_energy}$$

$$\text{iter_ratio} = 1$$

수정 : ‘ 모든 memory pair 가 duration-scaled ’ 라는
설명은 현재 코드와 맞지 않는다 .

Tensor matched-ITER 예외



Energy Run 과 NCU Sidecar 의 역할 분리

Energy Run

NCU detached

약 10 s 로 ITER calibration

NVML total-energy before/after

idle baseline 제거

treatment-control ΔE 생성

출력 : Joule numerator

NCU Sidecar

별도 profiler replay

같은 W_SM/B/SM/RF/LR 좌표

HMMA · cache hit/miss · bytes/access

local/spill · occupancy · stall

path acceptance 와 denominator scale

출력 : path/traffic evidence

NCU counter 는 component energy 를 직접 측정하지 않는다 .

Tensor logical FLOP denominator




logical_FLOP = N_MMA × 8192
 warp m16n16k16: 4096 FMA =
 8192 FLOP

pJ/FLOP = $\Delta E_{\text{tensor}} \times 10^{12}$
 $\div \text{logical_FLOP}$

NCU 의 HMMA instruction 은 denominator 자체가 아니다 . Treatment 에 Tensor instruction 이 있고 , control 에는 없으며 , spill/local 및 과도한 memory traffic 이 없는지를 검증한다 .

Memory traffic denominator 와 NCU scale



$$\text{pJ/byte} = \Delta E \times 10^{12} / \text{final_bytes}$$


$$\text{pJ/bit} = \text{pJ/byte} \div 8$$

ncu_actual_exact	mode·W·B·SM·factor exact match	strict final 허용
ncu_actual_same_working_set	같은 W/B/SM, factor scale 재사용	민감도 · 보조
expected_no_ncu_match	일치 NCU row 없음	strict memory reject

NCU path acceptance 와 spill evidence



Audit 단계별 상태 체계



서로 다른 단계의 상태를 하나의 'confidence' 등급처럼 합치지 않는다 .

RTX 3090 snapshot 과 DRAM 최신 보고 범위

2026-07-08 accepted strict snapshot: 4 rows


2026-07-12 current-protocol reaudit: fail

all rows: nvml_total_energy · total_energy_mj_delta · gpu_device_total_energy_counter

Tensor · pJ/FLOP



Historical on-chip snapshot · pJ/bit



DRAM provisional band
26.709-28.409 pJ/bit

Result	Snapshot pair → active pair	Condition	Denominator / NCU evidence	Reliability / current
Tensor 0.129 pJ/FLOP	reg_mma - reg_operand_only → same pair	W2048 KiB · B16 · SM82 RF8,16	logical FLOP HMMA treatment · legacy control/spill schema	accepted · medium current rerun
Shared 0.171 pJ/bit	shared_scalar - clocked_empty → same pair	W64 KiB · B16 · SM82 LR8	ncu_actual_exact shared bytes 1.0748e12	accepted · medium current rerun
Global L1 0.173 pJ/bit	global_l1 - clocked_empty → global_l1 - global_addr	W16 KiB · B16 · SM82 LR4	ncu_actual_exact L1 hit 99.9995%	accepted · medium pair changed
L2 CG 1.131 pJ/bit	l2_cg - clocked_empty → l2_cg - global_addr	W64 KiB · B16 · SM82 LR4,8	ncu_actual_exact L1 ≈0% · L2 hit ≈99.985%	accepted · medium pair changed
DRAM cumulative path 26.709-28.409 pJ/bit	target: dram_cg - global_addr legacy clocked_empty excluded	W8192 KiB · matched ITER current raw pair 없음	target denominator exact NCU dram_bytes × 8	provisional range strict eligible = false

DRAM 26.709-28.409 pJ/bit 는 최신 provisional cumulative-path band 다 . matched-ITER address-control raw pair 가 없으므로 accepted 실측값이나 physical GDDR6X energy 로 쓰지 않는다 .

Cross-platform 상태 · 한계 · 재현 checklist

Evidence stage	RTX 3090	V100	A100	H100
Repository profile	확인	확인	확인	확인
Command package	확인	확인	확인	확인
Raw energy artifact	historical 있음	missing	missing	missing
Fresh NCU acceptance	current fail	missing	missing	missing
Reliability audit	historical 있음	missing	missing	missing
Strict component summary	historical 4-row	missing	missing	missing
Package audit complete	아니오	아니오	아니오	아니오

재현 전 필수

1. strict preflight + runtime profile
2. clean architecture-specific build
3. total-energy scope row 확인
4. exact-coordinate treatment/control NCU
5. package audit 0 fail · 0 missing

남은 해석 한계

- target profile 은 SKU 보편값이 아님
- H100 은 WMMA, WGMMMA/TMA 가 아님
- DRAM 은 hierarchy sanity
- coefficient 는 workload-dependent
- external board power 가 아님

완료 조건 : Energy + NCU + denominator + power/stability + strict/package audit 가 같은 좌표와 provenance 로 연결될 것