


측정에서 Strict Coefficient 까지

GPU/device-level energy · Treatment-Control · NCU path validation

핵심 해석


**workload-dependent effective
microbenchmark coefficient**

github.com/bang001/gpupower0701
branch main · HEAD 0828f57 · dirty worktree · 2026-07-12



무엇을 해결하려는 실험인가

GPU 전체에서 관측한 에너지를 , 경로가 검증된 미세벤치마크의 단위 작업당 증분으로 바꾼다 .



어떤 kernel 과 control 을 비교했는가 ?

NCU 는 무엇을 검증했는가 ?

어떤 gate 가 final 채택을 막는가 ?

NVML 은 어떤 scope 를 측정했는가 ?

분모는 expected 인가 actual traffic 인가 ?

플랫폼별 완료 상태는 어디까지인가 ?

측정하는 것과 측정하지 않는 것

말할 수 있는 것

NVML GPU/device-level energy 를
Treatment-Control 방식으로 차분하고,
NCU counter 로 경로 · traffic denominator 를 검증한
**workload-dependent effective
microbenchmark coefficient**


- 특정 kernel · working set · occupancy · clock 상태에 의존
- pJ/FLOP 또는 pJ/bit 는 정규화 단위
- GPU/device scope 이며 외부 board meter 측정과 동일하지 않음

말하면 안 되는 것

- × 순수 Tensor Core 회로 에너지
- × 순수 register-file access energy
- × 순수 SRAM/HBM/GDDR bitcell energy
- × 모든 application 의 GPU 고정 상수
- × **NCU 가 직접 측정한 component energy**


board-level 은 더 넓은 전원 경계를 암시한다 . 본 코드가 명시적으로 기록하는 scope 는 `gpu_device_total_energy_counter` 다 .

시스템 구성 : 한 workload, 두 관측 채널




그림의 계측기는 개념 표현이다 . 실제 코드는 외부 전력계를 사용하지 않고 NVML API 를 호출한다 .

GPU 계층과 실험이 거냥하는 경로




저장소 architecture map



우선순위 : 코드 · CSV column → raw/NCU artifact → audit 결과 → 설명 문서

Current active treatment-control pair

Component/path	Treatment	Control	Final unit
Tensor MMA increment	reg_mma	reg_operand_only	pJ/FLOP
Shared scalar path	shared_scalar_load_only	clocked_empty	pJ/bit
Global L1 hit path	global_l1_load_only	global_addr_only	pJ/bit
L2 CG hit path	l2_cg_load_only	global_addr_only	pJ/bit
DRAM streaming sanity	dram_cg_load_only	global_addr_only	pJ/bit · sanity




Control 의 역할

비용을 최대한 보존하고 target operation


주의 : l2_load_only 는 normal global load 이므로 strict L2-only 증거로 자동 채택하지 않는다 .

설명용 핵심 파이프라인



NCU 는 Energy Run 과 분리된 sidecar 다 . 같은 좌표의 실행 경로와 traffic 을 검증하지만 energy 를 측정하지 않는다 .

실제 command-package 파이프라인




어느 중간 단계가 실패해도 **triage artifact** 는 남기고 , **strict evidence package** 가 불완전하면 **shell** 은 **non-zero** 로 종료한다 .

Platform profile 과 blocks/SM sweep

Profile	SM	Shared/SM	L1+Shared/SM	L2	max blocks/SM	strict B/SM
RTX 3090	82	100 KiB	128 KiB	6 MiB	16	8
V100 32GB	80	96 KiB	128 KiB	6 MiB	32	32
A100	108	164 KiB	192 KiB	40 MiB	32	16
H100	132	228 KiB	256 KiB	50 MiB	32	16

플랫폼별 blocks/SM sweep와 strict NCU anchor


V100 B4/B16은 utilization 민감도 진단이며 strict anchor는 B32다. 요청 B는 실제 residency를 보장하지 않으므로 NCU occupancy/resource로 검증한다.



V100 은 B4/B16 민감도와 strict B32 를 측정한다 . 요청 B/SM 은 실제 동시 residency 가 아니므로 NCU occupancy/resource 로 확인한다 .


Platform 별 W_SM path sweep

플랫폼별 W_SM sweep: 의도한 경로 후보이며 자동 cache 이동이 아님



Shared는 별도 주소 공간이므로 W_SM 변화로 Global L1이 되지 않는다. Global load는 W_SM과 cache policy(.cg)로 후보를 만들고, NCU hit/access/bytes가 L1-L2-DRAM 채택을 결정한다.

CUDA host 실행 sequence



SMID gate: $\text{unique_SM} = \text{active_SM}$, $\text{total_blocks} = \text{active_SM} \times \text{blocks/SM}$, 각 사용 SM 에 동일한 resident block 수가 배치되어야 한다 .

NVML energy 와 idle-baseline 계산

NVML before

kernel execution

NVML after

$$\Delta E_{\text{raw}} = (E_{\text{after_mJ}} - E_{\text{before_mJ}}) / 1000$$

$$E_{\text{idle,scaled}} = E_{\text{idle}} \times t_{\text{kernel}} / t_{\text{idle}}$$

$$E_{\text{net}} = \Delta E_{\text{raw}} - E_{\text{idle,scaled}}$$

Final numerator gate

- ✓ `nvml_total_energy_supported = true`
- ✓ `energy_source = nvml_total_energy`
- ✓ `integration = total_energy_mj_delta`
- ✓ `scope = gpu_device_total_energy_counter`

GetPowerUsage = fallback/provisional
power.draw.* = metadata/diagnostic
Hopper module power · GPU memory power = component
numerator 사용 금지

Memory 차분 : duration scaling 과 DRAM 예외

Shared · Global L1 · L2

Treatment 와 control 의
ITER·elapsed 가 다를 수 있다 .

$$P_{\text{control}} = E_{\text{control},\text{net}} / t_{\text{control}}$$

$$E_{\text{control},\text{scaled}} = P_{\text{control}} \times t_{\text{treatment}}$$

$$\Delta E = E_{\text{treatment},\text{net}} - E_{\text{control},\text{scaled}}$$

elapsed ratio > 1.35 또는 신호가 너무 작으면 reject

DRAM final pair

현행 DRAM sanity 는
treatment/control work 를 동일하게 잠근다 .


$$\text{ITER}_{\text{dram}} = \text{ITER}_{\text{addr}}$$

$$\Delta E_{\text{DRAM}} = E_{\text{dram},\text{net}} - E_{\text{addr},\text{net}}$$

$$\text{pair_energy_basis} = \text{matched_iters_net_energy} \\ \text{iter_ratio} = 1$$

수정 : ‘ 모든 memory pair 가 duration-scaled ’ 라는
설명은 현재 코드와 맞지 않는다 .

Tensor matched-ITER 예외



Energy Run 과 NCU Sidecar 의 역할 분리

Energy Run

NCU detached

약 10 s 로 ITER calibration

NVML total-energy before/after

idle baseline 제거

treatment-control ΔE 생성

출력 : Joule numerator

NCU Sidecar

별도 profiler replay

같은 W_SM/B/SM/RF/LR 좌표

HMMA · cache hit/miss · bytes/access

local/spill · occupancy · stall

path acceptance 와 denominator scale

출력 : path/traffic evidence

NCU counter 는 component energy 를 직접 측정하지 않는다 .

Tensor logical FLOP denominator




logical_FLOP = $N_MMA \times 8192$
 warp m16n16k16: 4096 FMA =
 8192 FLOP

pJ/FLOP = $\Delta E_tensor \times 10^{12}$
 $\div$ **logical_FLOP**

NCU 의 HMMA instruction 은 denominator 자체가 아니다 . Treatment 에 Tensor instruction 이 있고 , control 에는 없으며 , spill/local 및 과도한 memory traffic 이 없는지를 검증한다 .

Memory traffic denominator 와 NCU scale



$$\text{pJ/byte} = \Delta E \times 10^{12} / \text{final_bytes}$$


$$\text{pJ/bit} = \text{pJ/byte} \div 8$$

ncu_actual_exact	mode·W·B·SM·factor exact match	strict final 허용
ncu_actual_same_working_set	같은 W/B/SM, factor scale 재사용	민감도 · 보조
expected_no_ncu_match	일치 NCU row 없음	strict memory reject

NCU path acceptance 와 spill evidence



Audit 단계별 상태 체계




서로 다른 단계의 상태를 하나의 'confidence' 등급처럼 합치지 않는다 .

RTX 3090 snapshot 과 DRAM 최신 보고 범위

2026-07-13 current Tensor: standalone

Current full component table: incomplete

all rows: nvml_total_energy · total_energy_mj_delta · gpu_device_total_energy_counter



DRAM provisional band
26.709-28.409 pJ/bit

Result	Pair / protocol transition	Condition	Denominator / NCU evidence	Reliability / current
Tensor 2.253 pJ/FLOP	reg_mma - reg_operand_only → matched ITER	W2048 KiB · B16 · SM82 RF1,2,4,8,16	logical FLOP HMMA/logical=2 · control=0 · local=0	current standalone medium-high · 33 pairs
Shared 0.171 pJ/bit	shared_scalar - clocked_empty → same pair	W64 KiB · B16 · SM82 LR8	historical exact shared bytes control schema predates current package	historical full rerun required
Global L1 0.173 pJ/bit	global_l1 - clocked_empty → global_l1 - global_addr	W16 KiB · B16 · SM82 LR4	historical treatment L1 hit 99.9995% address-control evidence missing	provisional historical pair changed
L2 CG 1.131 pJ/bit	l2_cg - clocked_empty → l2_cg - global_addr	W64 KiB · B16 · SM82 LR4,8	historical treatment L2 hit ≈99.985% address-control evidence missing	provisional historical pair changed
DRAM cumulative path 26.709-28.409 pJ/bit	target: dram_cg - global_addr legacy clocked_empty excluded	W8192 KiB · matched ITER current raw pair 없음	target denominator exact NCU dram_bytes × 8	provisional range strict eligible = false

DRAM 26.709-28.409 pJ/bit 는 최신 provisional cumulative-path band 다 . matched-ITER address-control raw pair 가 없으므로 accepted 실측값이나 physical GDDR6X energy 로 쓰지 않는다 .

Cross-platform 상태 · 한계 · 재현 checklist

Evidence stage	RTX 3090	V100	A100	H100
Repository profile	확인	확인	확인	확인
Command package	확인	확인	확인	확인
Raw energy artifact	Tensor current + historical	missing	missing	missing
Fresh NCU acceptance	Tensor 10/10 only	missing	missing	missing
Reliability audit	Tensor standalone	missing	missing	missing
Strict component summary	current full table 없음	missing	missing	missing
Package audit complete	아니오	아니오	아니오	아니오

재현 전 필수

1. strict preflight + runtime profile
2. clean architecture-specific build
3. total-energy scope row 확인
4. exact-coordinate treatment/control NCU
5. package audit 0 fail · 0 missing

남은 해석 한계

- target profile 은 SKU 보편값이 아님
- H100 은 WMMA, WGMMMA/TMA 가 아님
- DRAM 은 hierarchy sanity
- coefficient 는 workload-dependent
- external board power 가 아님

완료 조건 : Energy + NCU + denominator + power/stability + strict/package audit 가 같은 좌표와 provenance 로 연결될 것